



**UNIVERSIDADE ESTADUAL DE CAMPINAS – UNICAMP
INSTITUTO DE MATEMÁTICA, ESTATÍSTICA E
COMPUTAÇÃO CIENTÍFICA – IMECC**

Disciplina: ME731 - Métodos em Análise Multivariada
Professor: Aluísio de Souza Pinheiro

**Análise de Perfis Energéticos de Países por
meio da Análise de Componentes Principais e
da Distância de Mahalanobis**

Projeto 1: Análise Multivariada

Autor:
Eduardo Saegi de Souza Hsu
RA: 277142

**CAMPINAS
2026**

1 Introdução

O perfil energético de um país pode ser caracterizado por diferentes indicadores relacionados ao consumo de energia, ao consumo de eletricidade, à eficiência no uso de recursos e à intensidade de carbono da geração de eletricidade. Essas características estão inseridas em um contexto de crescente preocupação com as mudanças climáticas, o aquecimento global e o uso sustentável dos recursos energéticos. Dessa forma, analisar conjuntamente diferentes indicadores permite obter uma visão mais ampla das características energéticas dos países, evitando que o comportamento de cada país seja avaliado a partir de uma única dimensão.

Neste trabalho são analisados quatro indicadores energéticos para um conjunto de 165 países: energia per capita, eletricidade per capita, intensidade de carbono da eletricidade e energia por unidade de PIB. Os dados são provenientes da base de dados de energia do Our World in Data, que reúne informações de diferentes fontes sobre consumo de energia, eletricidade, emissões, intensidade de carbono, população e produto interno bruto [1]. A base disponibiliza indicadores em diferentes escalas, incluindo medidas per capita e medidas relacionadas ao PIB.

Como os quatro indicadores são observados simultaneamente para cada país e podem apresentar relações entre si, sua análise deve considerar não apenas o comportamento individual de cada variável, mas também sua estrutura conjunta de variabilidade e associação. Nesse contexto, são utilizadas duas técnicas principais: a Análise de Componentes Principais (PCA) e a Distância de Mahalanobis.

A análise foi realizada utilizando o ambiente R e o RStudio [2]. O objetivo geral deste trabalho é investigar como os indicadores energéticos se estruturam conjuntamente entre os países e como essa estrutura pode ser utilizada para caracterizar a variabilidade multivariada e identificar observações que apresentem maior afastamento em relação ao comportamento geral da amostra.

Como objetivos específicos, busca-se:

1. caracterizar a estrutura de variabilidade conjunta dos indicadores por meio da PCA;
2. interpretar as principais direções de variabilidade identificadas pelas componentes principais;
3. avaliar a contribuição das diferentes variáveis para as componentes principais;
4. calcular a Distância de Mahalanobis para quantificar o afastamento multivariado das observações;
5. investigar quais componentes principais contribuem mais para os afastamentos observados.

2 Fundamentação Teórica e Metodologia

Esta seção é dedicada para a fundamentação das duas técnicas que serão aplicadas neste projeto, de maneira a explicar sua teoria e aplicação.

2.1 Distância de Mahalanobis

Grande parte das técnicas de análise multivariada envolve a comparação entre observações por meio de medidas de distância. A distância Euclidiana, por exemplo, é uma medida simples, mas não leva em consideração a variabilidade individual das variáveis nem as correlações existentes entre elas.

Em dados multivariados, essas características são importantes para determinar se uma observação está próxima ou distante do centro da distribuição.

A Distância de Mahalanobis foi desenvolvida justamente para incorporar a estrutura de variâncias e covariâncias dos dados. Considerando uma observação $\mathbf{x}$, um vetor de médias $\boldsymbol{\mu}$ e uma matriz de covariâncias $\boldsymbol{\Sigma}$, define-se

$$D_M(\mathbf{x}) = \sqrt{(\mathbf{x} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})}. \quad (1)$$

Frequentemente utiliza-se o quadrado da distância,

$$D_M^2 = (\mathbf{x} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}). \quad (2)$$

Como os parâmetros populacionais normalmente são desconhecidos, são utilizadas as estimativas amostrais:

$$D_M^2 = (\mathbf{x} - \bar{\mathbf{x}})' S^{-1} (\mathbf{x} - \bar{\mathbf{x}}), \quad (3)$$

em que $\bar{\mathbf{x}}$ representa o vetor de médias amostrais e S representa a matriz de covariâncias amostral [3].

A principal diferença em relação à distância Euclidiana é a presença de S^{-1} . Uma variável com grande variabilidade tende a contribuir menos para a distância, enquanto um desvio em uma direção de baixa variabilidade tende a produzir uma contribuição relativamente maior. Além disso, as covariâncias entre as variáveis são incorporadas ao cálculo.

Uma interpretação importante pode ser obtida pela transformação

$$\mathbf{z} = \boldsymbol{\Sigma}^{-1/2} (\mathbf{x} - \boldsymbol{\mu}). \quad (4)$$

Nesse novo sistema de coordenadas,

$$\text{Cov}(\mathbf{Z}) = \mathbf{I}, \quad (5)$$

de modo que as novas coordenadas apresentam variância unitária e não possuem correlação. Consequentemente,

$$D_M^2 = \mathbf{z}'\mathbf{z}. \quad (6)$$

Assim, a Distância de Mahalanobis pode ser interpretada como uma distância Euclidiana depois de uma transformação que padroniza e decorrelaciona as variáveis [3].

2.2 Interpretação geométrica

Os pontos que satisfazem

$$(\mathbf{x} - \boldsymbol{\mu})'\boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) = c \quad (7)$$

formam, em duas dimensões, uma elipse e, em dimensões superiores, um elipsoide.

A forma e a orientação dessa estrutura são determinadas pela matriz de covariâncias.

Considerando a decomposição espectral

$$\boldsymbol{\Sigma} = A\Lambda A', \quad (8)$$

os autovetores de A determinam as direções principais dos eixos, enquanto os autovalores de Λ determinam a variabilidade associada a essas direções.

Quando os dados seguem uma distribuição normal multivariada,

$$\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}), \quad (9)$$

tem-se, sob parâmetros populacionais conhecidos,

$$D_M^2 \sim \chi_p^2. \quad (10)$$

Entretanto, quando a média e a matriz de covariâncias são estimadas a partir da própria amostra, a estatística resultante não apresenta, em geral, essa distribuição qui-quadrado de forma exata.

2.3 Análise de Componentes Principais

A Análise de Componentes Principais é uma técnica utilizada para representar a variabilidade de um conjunto de variáveis por meio de combinações lineares não correlacionadas. A PCA pode ser utilizada para redução da dimensionalidade [3].

Considere o vetor aleatório

$$\mathbf{X} = (X_1, X_2, \dots, X_p)'. \quad (11)$$

Uma combinação linear das variáveis é dada por

$$Y_i = \mathbf{a}_i' \mathbf{X}. \quad (12)$$

Sua variância é

$$\text{Var}(Y_i) = \mathbf{a}_i' \boldsymbol{\Sigma} \mathbf{a}_i. \quad (13)$$

A primeira componente principal é definida como a combinação linear que maximiza essa variância, sujeita à restrição

$$\mathbf{a}_1' \mathbf{a}_1 = 1. \quad (14)$$

A solução corresponde ao autovetor associado ao maior autovalor da matriz de covariâncias.

As componentes seguintes são construídas de maneira análoga, utilizando os autovetores associados aos demais autovalores e impondo ortogonalidade entre os vetores de coeficientes.

Assim,

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0. \quad (15)$$

A variância total é

$$\text{tr}(\boldsymbol{\Sigma}) = \lambda_1 + \lambda_2 + \dots + \lambda_p. \quad (16)$$

A proporção da variância explicada pela componente i é

$$\frac{\lambda_i}{\lambda_1 + \lambda_2 + \dots + \lambda_p}. \quad (17)$$

A proporção acumulada pelas primeiras k componentes é

$$\frac{\lambda_1 + \cdots + \lambda_k}{\lambda_1 + \cdots + \lambda_p}. \quad (18)$$

2.4 Scores e cargas fatoriais

Os *scores* representam as coordenadas das observações no novo sistema de coordenadas definido pelas componentes principais.

Se

$$A = [\mathbf{a}_1 \ \mathbf{a}_2 \ \cdots \ \mathbf{a}_p], \quad (19)$$

então, para uma observação centrada,

$$\mathbf{y} = A'(\mathbf{x} - \boldsymbol{\mu}). \quad (20)$$

Os coeficientes dos autovetores são utilizados na interpretação das componentes. Valores absolutos elevados indicam maior associação da variável com a componente correspondente.

2.5 Relação entre PCA e Distância de Mahalanobis

A relação entre as duas técnicas pode ser observada diretamente pela decomposição espectral da matriz de covariâncias:

$$\boldsymbol{\Sigma} = A\Lambda A'. \quad (21)$$

Como A é ortogonal,

$$\boldsymbol{\Sigma}^{-1} = A\Lambda^{-1}A'. \quad (22)$$

Substituindo essa expressão na Distância de Mahalanobis,

$$D_M^2 = (\mathbf{x} - \boldsymbol{\mu})' A\Lambda^{-1}A'(\mathbf{x} - \boldsymbol{\mu}). \quad (23)$$

Definindo

$$\mathbf{y} = A'(\mathbf{x} - \boldsymbol{\mu}), \quad (24)$$

obtém-se

$$D_M^2 = \mathbf{y}' \Lambda^{-1} \mathbf{y}. \quad (25)$$

Como Λ é diagonal,

$$D_M^2 = \sum_{j=1}^p \frac{Y_j^2}{\lambda_j}. \quad (26)$$

Essa expressão é fundamental para a interpretação dos resultados. Cada componente principal contribui para a Distância de Mahalanobis por meio de seu *score* ao quadrado, dividido pelo respectivo autovalor.

Portanto, uma direção de baixa variabilidade pode contribuir significativamente para a distância mesmo quando explica uma pequena parcela da variância total.

3 Descrição e análise exploratória dos dados

Esta seção é dedicada para explicar e analisar a estrutura do conjunto de dados utilizado no projeto.

3.1 Construção e preparação do conjunto de dados

Os dados utilizados neste trabalho foram obtidos da base de dados *Our World in Data*, considerando informações referentes ao ano de 2022. A escolha desse ano deve-se à disponibilidade conjunta das variáveis utilizadas na análise e à necessidade de trabalhar com um mesmo período de referência para todas as unidades observacionais.

Foram selecionados quatro indicadores relacionados ao consumo e à intensidade energética que são, energia per capita, representa a quantidade de energia associada, em termos médios, a cada habitante de um país. É utilizada como indicador do nível de consumo energético por pessoa. Sua unidade é kWh por pessoa.

Elettricidade per capita, representa o consumo ou uso de eletricidade por habitante e permite caracterizar especificamente a dimensão elétrica do perfil energético. Sua unidade é kWh por pessoa.

Intensidade de carbono da eletricidade, representa a quantidade de emissões de carbono associada à geração de eletricidade. Valores maiores indicam uma geração elétrica relativamente mais intensiva em carbono. Sua unidade é gCO_2/kWh .

Energia por PIB, representa a quantidade de energia utilizada em relação ao produto interno bruto. Essa variável permite caracterizar a intensidade energética da economia, relacionando o uso de energia à atividade econômica. Sua unidade é kWh por dólar internacional de PIB.

As quatro variáveis foram selecionadas por representarem diferentes dimensões relacionadas ao uso de energia e por terem poucos dados faltantes para uma quantidade grande de países.

A seleção dos dados foi realizada inicialmente restringindo a base ao ano de 2022. Foram eliminadas as observações que apresentavam pelo menos um valor ausente entre as quatro variáveis de interesse.

Assim, o conjunto efetivamente utilizado é formado pelas unidades que possuem informação simultaneamente disponível para os quatro indicadores no ano de 2022 e não necessariamente por todos países existentes na base original.

A Tabela 1 apresenta as estatísticas descritivas das variáveis na escala original.

Tabela 1: Estatísticas descritivas das variáveis na escala original.

Variável	Média	Mediana	DP	Assimetria	Curtose
Energia per capita	25390.09	14172.19	33991.97	2.55	7.38
Eletricidade per capita	4064.96	2288.83	5904.68	4.22	26.80
Intensidade de carbono da eletricidade	412.17	438.06	245.76	0.24	-0.10
Energia por PIB	1.17	0.97	0.79	2.53	7.90

A Tabela 1 mostra diferenças marcantes entre as distribuições.

Para energia per capita, a média de 25390.09 é consideravelmente maior que a mediana de 14172.19. Essa diferença é consistente com a assimetria positiva de 2.55, indicando a presença de países com valores muito elevados em comparação ao centro da distribuição.

O comportamento é ainda mais pronunciado para eletricidade per capita. A média é 4064.96, enquanto a mediana é 2288.83, e a assimetria atinge 4.22. A curtose de 26.80 também é bastante elevada, indicando uma distribuição com caudas muito mais pronunciadas do que aquelas esperadas em uma distribuição aproximadamente normal.

A intensidade de carbono da eletricidade apresenta comportamento diferente. Sua assimetria é apenas 0.24 e a curtose é -0.10 , indicando uma distribuição mais próxima da simetria e com comportamento menos extremo que as demais variáveis.

Já energia por PIB apresenta assimetria positiva de 2.53 e curtose de 7.90, indicando novamente uma distribuição com valores elevados concentrados em uma parcela relativamente pequena dos países.

A Figura 1 apresenta os histogramas das quatro variáveis na escala original.




Figura 1: Histogramas das variáveis na escala original.

Os histogramas permitem visualizar graficamente os resultados da Tabela 1. As distribuições de energia per capita, eletricidade per capita e energia por PIB apresentam caudas alongadas à direita. Esse comportamento é compatível com os elevados coeficientes de assimetria observados.

A eletricidade per capita é particularmente assimétrica, o que está de acordo com seu coeficiente de assimetria igual a 4.22 e sua elevada curtose.

A distribuição da intensidade de carbono da eletricidade é visualmente mais equilibrada, confirmando a menor assimetria apresentada na tabela.

A Figura 2 apresenta os QQ-plots das variáveis originais.




Figura 2: QQ-plots das variáveis na escala original.

Nos QQ-plots, a aproximação dos pontos à reta de referência seria esperada caso as distribuições fossem aproximadamente normais. Os desvios observados, principalmente nas variáveis de consumo energético, são consistentes com os resultados das estatísticas de assimetria e curtose.

Assim, tanto as estatísticas descritivas quanto a inspeção gráfica apontam para desvios relevantes em relação à normalidade.

As Figuras 3–6 apresentam as elipses de densidade bivariada das combinações entre as variáveis.




Figura 3: Elipse de densidade bivariada entre Elettricidade per capita e Energia per capita.




Figura 4: Elipse de densidade bivariada entre Intensidade de carbono da eletricidade e Energia per capita.




Figura 5: Elipse de densidade bivariada entre Intensidade de carbono da eletricidade e Eletricidade per capita.




Figura 6: Elipse de densidade bivariada Intensidade de carbono da eletricidade e Energia por PIB.

A análise das elipses de densidade bivariada originais revela que as variáveis não seguem uma distribuição normal conjunta. As principais evidências observadas são a presença marcante de valores discrepantes, especialmente nas Figuras 3, 5 e 6, onde diversos pontos encontram-se distantes dos limites da elipse de confiança.

Além disso, nas Figuras 4 e 5, os dados apresentam uma concentração extrema e assimétrica. Em vez de formarem uma nuvem elíptica com maior densidade no centro, os pontos formam uma densa barra vertical agrupada próxima ao valor zero no eixo horizontal.

Ademais a Figura 6 exibe um forte achatamento à esquerda com uma cauda longa à direita, apresentando pontos atípicos que ultrapassam o valor 4 no eixo correspondente. E na Figura 3, nota-se uma dispersão desproporcional com uma cauda

muito alongada à extrema direita, indicando um claro afastamento da simetria elíptica esperada para distribuições normais bivariadas.

4 Avaliação da normalidade

A normalidade foi avaliada tanto individualmente quanto conjuntamente. Para as variáveis individuais foi utilizado o teste de Anderson–Darling, enquanto a normalidade multivariada foi investigada por meio dos testes de assimetria e curtose de Mardia.

Tabela 2: Testes de normalidade das variáveis originais.

Nível	Teste	Estatística	p-valor	Conclusão
Multivariado	Mardia – Assimetria	1624.80	< 0.001	Não normal
Multivariado	Mardia – Curtose	77.83	< 0.001	Não normal
Univariado	Anderson–Darling – Energia per capita	14.475	< 0.001	Não normal
Univariado	Anderson–Darling – Eletricidade per capita	14.373	< 0.001	Não normal
Univariado	Anderson–Darling – Intensidade de carbono	2.014	< 0.001	Não normal
Univariado	Anderson–Darling – Energia por PIB	9.567	< 0.001	Não normal

Conforme apresentado na Tabela 2, todas as variáveis rejeitam a hipótese nula de normalidade ao nível de 5%.

Os resultados multivariados também rejeitam a hipótese de normalidade. A estatística de Mardia para assimetria é 1624.80 e a estatística para curtose é 77.83, ambas com $p < 0.001$.

Portanto, há evidências de que o vetor das quatro variáveis não segue uma distribuição normal multivariada.

Isso é importante para a interpretação da Distância de Mahalanobis. A associação de D_M^2 com uma distribuição qui-quadrado depende de condições adicionais relacionadas à normalidade multivariada.

A Figura 7 apresenta o QQ-plot do quadrado da Distância de Mahalanobis calculada sobre os dados originais.




Figura 7: QQ-plot do quadrado da Distância de Mahalanobis nos dados originais.

O QQ-plot é utilizado apenas como diagnóstico exploratório, uma vez que as distâncias foram calculadas utilizando a média e a matriz de covariâncias amostrais. Portanto, a distribuição qui-quadrado não constitui uma distribuição de referência exata para essas distâncias.

O afastamento dos pontos em relação ao comportamento esperado da referência teórica é compatível com a ausência de normalidade multivariada identificada pelos testes de Mardia.

5 Transformação das variáveis

Por conta da forte assimetria observada nas variáveis originais, foi considerada uma transformação logarítmica.

A transformação foi aplicada às variáveis energia per capita, eletricidade per capita e energia por PIB, que apresentam valores estritamente positivos na amostra.

A intensidade de carbono da eletricidade não foi transformada. Além de apresentar baixa assimetria na escala original, essa variável possui uma observação com valor igual a zero.

A Tabela 3 apresenta as estatísticas descritivas após a transformação.

Tabela 3: Estatísticas descritivas das variáveis após transformação.

Estatística	Energia per capita	Eletricidade per capita	Intensidade de carbono	Energia por PIB
Média	9.2549	7.3558	412.1652	-0.0113
Mediana	9.5590	7.7358	438.0600	-0.0284
Desvio-padrão	1.5344	1.6730	245.7562	0.5571
Assimetria	-0.4420	-0.6970	0.2400	0.3230
Curtose	-0.5880	-0.1790	-0.0982	0.4450

A Tabela 3 mostra uma redução da assimetria.

Para energia per capita, a assimetria passou de 2.55 para -0.442 . Para eletricidade per capita, passou de 4.22 para -0.697 . Para energia por PIB, passou de 2.53 para 0.323.

Também houve redução das medidas de curtose nas variáveis transformadas. Entretanto, a redução da assimetria não implica que os dados tenham passado a seguir uma distribuição normal multivariada.

5.1 Visualização após a transformação




Figura 8: QQ-plots das variáveis após transformação.

A Figura 8 mostra uma aproximação maior à reta de referência em comparação com os QQ-plots originais, especialmente para as variáveis que apresentavam forte assimetria.




Figura 9: Histogramas das variáveis após transformação.

Os histogramas da Figura 9 confirmam visualmente a redução das caudas observadas na escala original.

As Figuras 10–13 apresentam as elipses de densidade bivariada após a transformação.




Figura 10: Elipse de densidade bivariada entre Eletricidade per capita e Energia per capita após a transformação.




Figura 11: Elipse de densidade bivariada entre Intensidade de carbono da eletricidade e Energia per capita após a transformação.




Figura 12: Elipse de densidade bivariada Intensidade de carbono da eletricidade e Eletricidade per capita após a transformação.




Figura 13: Elipse de densidade bivariada entre Intensidade de carbono da eletricidade e Energia por PIB após a transformação.

Após a aplicação das transformações nos dados, nota-se uma melhora evidente no ajuste à multinormalidade. A comparação direta com o cenário não transformado demonstra que a assimetria severa e os valores extremos na escala original que se estendiam à direita na Figura 3 foram reduzidos. A Figura 10 exibe agora uma nuvem de pontos com formato elíptico bem definido e distribuição homogênea contida pela elipse.

O agrupamento em formato de barra vertical colado no eixo zero da Figura 4 transformou-se em uma nuvem dispersa de forma muito mais uniforme e bem abrigada pelos limites da elipse de densidade na Figura 11.

A concentração vertical densa original deu lugar a uma distribuição muito mais equilibrada ao longo de todo o eixo x na Figura 12, resultando em uma redução drástica dos valores discrepantes.

A dispersão assimétrica e com valores atípicos alongados teve sua escala comprimida e centralizada em torno de zero na Figura 13, conseguindo conter a maioria das observações dentro dos contornos da elipse.

Tabela 4: Matriz de correlação das variáveis log-transformadas

	Energia per capita	Eletricidade per capita	Intensidade de carbono da eletricidade	Energia por PIB
Energia per capita	1,0000	0,9495	0,1718	0,6871
Eletricidade per capita	0,9495	1,0000	0,0928	0,6167
Intensidade de carbono da eletricidade	0,1718	0,0928	1,0000	0,2890
Energia por PIB	0,6871	0,6167	0,2890	1,0000

A matriz de correlação apresentada na Tabela 4 permite avaliar a intensidade das associações lineares entre as variáveis após as transformações logarítmicas. Observa-se uma correlação elevada entre Energia per capita e Eletricidade per capita,

com coeficiente de correlação igual a 0,9495. Esse resultado indica que essas duas variáveis apresentam comportamento linear bastante semelhante na amostra analisada. Também são observadas correlações positivas e de magnitude moderada entre Energia por PIB e Energia per capita ($r = 0,6871$) e entre Energia por PIB e Eletricidade per capita ($r = 0,6167$).

Por outro lado, a Intensidade de carbono da eletricidade apresenta correlações relativamente baixas com Energia per capita ($r = 0,1718$) e Eletricidade per capita ($r = 0,0928$), embora apresente uma associação positiva um pouco maior com Energia por PIB ($r = 0,2890$). Portanto, a matriz sugere a existência de uma estrutura de dependência entre os indicadores, mas também evidencia que a Intensidade de carbono da eletricidade possui um comportamento relativamente distinto das demais variáveis.

A forte correlação observada entre Energia per capita e Eletricidade per capita fornece uma justificativa empírica para a utilização da Análise de Componentes Principais, uma vez que parte da informação contida nas variáveis pode ser sintetizada por combinações lineares de menor dimensão. Espera-se, portanto, que uma das primeiras componentes concentre uma parcela substancial da variabilidade conjunta dessas variáveis.

6 Avaliação da normalidade após a transformação

Os testes de normalidade foram repetidos após a transformação.

Tabela 5: Testes de normalidade após a transformação.

Nível	Teste	Estatística	p-valor	Conclusão
Multivariado	Mardia – Assimetria	83.935	< 0.001	Não normal
Multivariado	Mardia – Curtose	4.543	< 0.001	Não normal
Univariado	Anderson–Darling – Energia per capita	1.763	< 0.001	Não normal
Univariado	Anderson–Darling – Eletricidade per capita	2.985	< 0.001	Não normal
Univariado	Anderson–Darling – Intensidade de carbono	2.014	< 0.001	Não normal
Univariado	Anderson–Darling – Energia por PIB	0.481	0.230	Não rejeita normalidade

A Tabela 5 mostra uma melhora considerável nas estatísticas de Mardia.

A estatística de assimetria multivariada diminuiu de 1624.80 para 83.935, enquanto a estatística de curtose diminuiu de 77.83 para 4.543.

Apesar dessa redução, ambos os testes continuam apresentando $p < 0.001$. Assim, a hipótese de normalidade multivariada permanece rejeitada.

Nos testes univariados, a variável energia por PIB apresentou $p = 0.230$, não havendo evidência para rejeitar sua normalidade isoladamente. As demais variáveis continuam apresentando rejeição da normalidade.

A transformação, portanto, melhorou substancialmente as propriedades distributivas, mas não tornou o conjunto de dados normal multivariado.

A Figura 14 apresenta o QQ-plot do quadrado da Distância de Mahalanobis após a transformação.




Figura 14: QQ-plot do quadrado da Distância de Mahalanobis após a transformação.

Novamente o QQ-plot é utilizado apenas como diagnóstico exploratório, dado que as distâncias foram calculadas utilizando a média e a matriz de covariâncias amostrais. Portanto, a distribuição qui-quadrado não constitui uma distribuição de referência exata para essas distâncias.

Embora a transformação tenha reduzido os desvios observados nos dados, a normalidade multivariada não foi estabelecida.

7 Análise de Componentes Principais

Após a transformação, as variáveis foram padronizadas e a PCA foi realizada utilizando a matriz de correlação.

A padronização é importante porque as variáveis possuem escalas e unidades diferentes. Dessa maneira, cada indicador passa a ter variância unitária antes da obtenção das componentes.

Tabela 6: Autovalores e proporção da variância explicada pelas componentes principais.

Componente	Autovalor	Desvio-padrão	Variância explicada (%)	Variância acumulada (%)
PC1	2.5738	1.6043	64.35	64.35
PC2	0.9822	0.9911	24.56	88.90
PC3	0.3998	0.6323	10.00	98.90
PC4	0.0441	0.2100	1.10	100.00

A Tabela 6 mostra que a primeira componente possui autovalor igual a 2.5738 e explica 64.35% da variância total.

A segunda componente apresenta autovalor 0.9822 e explica mais 24.56%.

Consequentemente, as duas primeiras componentes acumulam 88.90% da variabilidade total. Isso significa que uma representação dos dados no plano formado por PC1 e PC2 preserva grande parte da estrutura de variabilidade da amostra.

A terceira componente acrescenta 10.00%, elevando a variância acumulada para 98.90%.

A quarta componente representa somente 1.10% da variância total.

7.1 Coeficientes dos autovetores das componentes principais

Tabela 7: Coeficientes das componentes principais.

Variável	PC1	PC2	PC3	PC4
Energia per capita	0.5972	-0.1685	-0.2761	-0.7340
Elettricidade per capita	0.5765	-0.2579	-0.3850	0.6730
Intensidade de carbono da eletricidade	0.1951	0.9431	-0.2658	0.0423
Energia por PIB	0.5224	0.1249	0.8396	0.0806

A Tabela 7 permite interpretar o significado das componentes.

A PC1 apresenta cargas positivas relativamente elevadas para energia per capita (0.5972), eletricidade per capita (0.5765) e energia por PIB (0.5224). A carga da intensidade de carbono da eletricidade é menor, com valor 0.1951.

A PC2 apresenta uma carga muito elevada para intensidade de carbono da eletricidade, igual a 0.9431.

A PC3 apresenta sua maior carga em energia por PIB, com valor 0.8396.

Por fim, a PC4 apresenta cargas de sinais opostos para energia per capita e eletricidade per capita, respectivamente -0.7340 e 0.6730 .

7.2 Distribuição dos países no espaço das componentes

A Figura 15 apresenta a distribuição dos países no plano formado pelas duas primeiras componentes principais.




Figura 15: Distribuição dos países no espaço formado por PC1 e PC2.

Como PC1 e PC2 explicam conjuntamente 88.90% da variância, a figura fornece uma representação bastante informativa da estrutura dos dados.

A posição de cada país nesse gráfico é determinada pelos seus *scores*. Países próximos apresentam perfis semelhantes nas direções representadas por PC1 e PC2, enquanto países afastados apresentam diferenças mais acentuadas nessas dimensões.

É importante destacar que a proximidade visual no plano não equivale necessariamente à proximidade na Distância de Mahalanobis completa, pois esta última considera também PC3 e PC4.




Figura 16: Gráfico de sedimentação dos autovalores da análise de componentes principais. A linha tracejada indica o critério de Kaiser, correspondente ao autovalor igual a 1.

O Gráfico 16 apresenta o gráfico de sedimentação (*scree plot*) dos quatro autovalores obtidos na análise de componentes principais. A linha horizontal tracejada representa o valor $\lambda = 1$, utilizado como referência pelo critério de Kaiser.

Os autovalores obtidos foram aproximadamente 2,5738, 0,9822, 0,3998 e 0,0441 para as quatro componentes, respectivamente. Pelo critério de Kaiser, seriam retidas as componentes cujo autovalor fosse maior que um. Dessa forma, apenas a primeira componente satisfaz estritamente esse critério.

O gráfico também evidencia uma queda acentuada do primeiro para o segundo autovalor, seguida de uma redução progressivamente menor entre as componentes seguintes. Assim, embora o critério de Kaiser indique estritamente a retenção de apenas uma componente, a segunda componente ainda representa uma parcela relevante da variabilidade, de aproximadamente 24,56%.

Neste trabalho, opta-se por utilizar as duas primeiras componentes para a representação bidimensional dos dados, como uma escolha de redução de dimensionalidade baseada na elevada proporção de variância acumulada e na possibilidade de interpretar conjuntamente as duas componentes.

A estrutura observada na matriz de correlação, especialmente a forte associação entre Energia per capita e Eletricidade per capita, é compatível com a concentração de grande parte da variabilidade na primeira componente. Ao mesmo tempo, a existência de uma segunda componente próxima ao limite de Kaiser mostra que a decisão sobre a dimensionalidade não é totalmente determinada por esse critério.

8 Distância de Mahalanobis

A Distância de Mahalanobis foi calculada utilizando as quatro variáveis transformadas e padronizadas.

Para cada país, foi calculada a distância quadrática em relação ao centro multivariado da amostra.

No sistema de componentes principais, a distância pode ser expressa por

$$D_M^2 = \sum_{j=1}^4 \frac{Y_j^2}{\lambda_j}. \quad (27)$$

Essa expressão permite decompor a distância total em contribuições associadas às quatro componentes.

Assim, uma contribuição elevada pode ocorrer por dois motivos: um *score* elevado ou um autovalor pequeno.

Tabela 8: Países com maiores Distâncias de Mahalanobis e contribuição das componentes.

País	D_M^2	PC1	PC2	PC3	PC4	Principal
Afeganistão	18.758	2.814	0.061	5.210	10.673	PC4
Turcomenistão	18.022	4.170	11.927	1.823	0.101	PC2
Coreia do Norte	17.672	0.431	0.038	16.018	1.186	PC3
Luxemburgo	16.159	0.138	1.567	0.012	14.442	PC4
Moçambique	14.168	0.193	0.382	7.617	5.977	PC3
Venezuela	13.724	1.147	0.559	11.964	0.055	PC3
Islândia	13.049	4.202	4.108	3.648	1.091	PC1
Serra Leoa	12.866	4.716	0.379	1.361	6.411	PC4
Paraguai	11.859	0.006	3.014	0.071	8.768	PC4
Laos	11.305	0.078	0.711	0.057	10.459	PC4
Trinidad e Tobago	10.851	3.678	0.827	4.064	2.281	PC3
Chade	10.160	4.871	2.452	0.167	2.670	PC1
Rep. Dem. do Congo	10.114	4.117	0.913	0.125	4.959	PC4
Zimbábue	8.864	0.003	0.000	8.050	0.811	PC3
Bahrein	8.567	5.454	2.264	0.738	0.110	PC1

A Tabela 8 apresenta os países com maiores valores de D_M^2 .

Os resultados mostram que países diferentes podem apresentar grandes distâncias por razões distintas. Portanto, a Distância de Mahalanobis não apenas permite identificar observações afastadas do centro multivariado, mas também permite investigar quais dimensões são responsáveis por esse afastamento.

8.1 Distribuição das Distâncias

A Figura 17 apresenta a distribuição dos valores da Distância de Mahalanobis.




Figura 17: Distribuição das Distâncias de Mahalanobis.

A figura mostra que a maior parte das observações possui valores relativamente menores de D_M^2 , enquanto um conjunto reduzido de países apresenta valores substancialmente maiores.

Esses valores elevados representam países que se encontram mais afastados do centro multivariado segundo a estrutura de variabilidade estimada.

Entretanto, devido à ausência de normalidade multivariada, esses valores são tratados neste trabalho como medidas descritivas de afastamento, e não como resultados de um teste formal de observações discrepantes.

Tabela 9: Estatísticas descritivas da Distância de Mahalanobis.

Estatística	Mínimo	Q1	Mediana	Média	Q3	Máximo
D_M^2	0.148	1.555	2.982	3.976	5.119	18.758

A Tabela 9 mostra que a mediana da Distância de Mahalanobis quadrática é 2.982, enquanto a média é 3.976. A diferença entre média e mediana é compatível com a existência de algumas observações com distâncias elevadas.

9 Discussão crítica

A aplicação conjunta da Análise de Componentes Principais (PCA) e da Distância de Mahalanobis permitiu analisar os quatro indicadores energéticos de forma complementar. A PCA foi utilizada para identificar as principais direções de variabilidade

e obter uma representação de menor dimensão dos dados, enquanto a Distância de Mahalanobis permitiu quantificar o afastamento de cada país em relação ao centro multivariado, considerando simultaneamente as variâncias e as associações entre as variáveis. Os resultados obtidos mostram que essas duas perspectivas não produzem necessariamente as mesmas conclusões, mas podem ser utilizadas conjuntamente para caracterizar a estrutura dos dados.

9.1 Vantagens e limitações da Análise de Componentes Principais

A principal contribuição da PCA neste projeto está em sua capacidade de reduzir a dimensionalidade dos dados, sintetizando a estrutura de variabilidade dos quatro indicadores originais em um número menor de componentes. Essa propriedade é particularmente relevante para a análise exploratória em contextos de alta dimensionalidade.

No caso deste projeto permite representar simultaneamente os países em um número menor de dimensões, facilitando a visualização e a identificação de padrões. Após a transformação logarítmica e a padronização das variáveis, a primeira componente explicou 64,35% da variância total e a segunda acrescentou 24,56%, de modo que as duas primeiras componentes concentraram 88,90% da variabilidade. Dessa forma, a representação dos países no plano formado por PC1 e PC2 preserva grande parte da estrutura de variabilidade presente nas quatro variáveis originais, permitindo uma representação bidimensional substancialmente mais simples dos dados.

Essa redução, entretanto, envolve uma importante perda de interpretabilidade. As componentes principais não correspondem necessariamente a dimensões diretamente observáveis ou a constructos com significado substantivo único, mas são combinações lineares das variáveis originais determinadas pela estrutura de covariância dos dados. A análise dos coeficientes permite, ainda assim, identificar quais indicadores apresentam maior associação com cada direção de variação, embora essa interpretação deva ser realizada com cautela.

A PC1 apresentou coeficientes positivos de magnitude elevada para Energia per capita (0,5972), Eletricidade per capita (0,5765) e Energia por PIB (0,5224), enquanto o coeficiente associado à Intensidade de carbono da eletricidade foi menor (0,1951). Assim, a PC1 pode ser descrita como uma direção de variação predominantemente associada aos indicadores de consumo e intensidade energética. Essa descrição, contudo, não significa que a componente possua um significado independente ou diretamente observável, mas apenas que essas variáveis apresentam maior associação com a direção representada pela PC1. A PC2, por sua vez, apresentou coeficiente de 0,9431 para a Intensidade de carbono da eletricidade, indicando uma associação particularmente forte dessa variável com a direção representada por essa componente.

Outro resultado relevante foi obtido a partir do critério de Kaiser, que indicou a retenção estrita apenas da PC1, uma vez que o segundo autovalor foi 0,9822, ligeiramente inferior a 1. Entretanto, a exclusão da PC2 produziria uma perda de 24,56% da variância total e eliminaria uma direção de variação fortemente associada à Intensidade

de carbono da eletricidade. Por esse motivo, a utilização das duas primeiras componentes mostrou-se adequada aos objetivos exploratórios e de visualização deste projeto. O resultado evidencia que critérios automáticos de retenção, embora úteis como referência, não devem ser considerados isoladamente, devendo ser avaliados em conjunto com a variância explicada e com os objetivos da análise.

A análise também evidenciou uma consequência importante da redução de dimensionalidade, uma componente que explica uma parcela pequena da variância global pode continuar sendo relevante para determinadas análises estatísticas. A PC4, por exemplo, explica apenas 1,10% da variância total e, sob a perspectiva de uma representação compacta da estrutura global dos dados, apresenta pouca relevância. Entretanto, essa mesma componente apresentou contribuições expressivas para algumas Distâncias de Mahalanobis. No caso do Afeganistão, por exemplo, a distância quadrática foi 18,758, sendo 10,673 provenientes da PC4. Para Luxemburgo, a contribuição da PC4 foi ainda maior, correspondendo a 14,442 de uma distância total de 16,159. Esses resultados mostram concretamente que a variância explicada não é um critério suficiente para determinar a relevância de uma componente para todos os objetivos estatísticos.

Consequentemente, a PCA mostrou-se especialmente adequada neste projeto como ferramenta de redução de dimensionalidade, síntese e visualização da estrutura global dos indicadores. Contudo, sua utilização envolve uma relação de compensação entre compactação e interpretabilidade, ao substituir as variáveis originais por um conjunto menor de componentes, obtém-se uma representação mais simples, mas perde-se parte da correspondência direta com os indicadores originais. Além disso, a retenção das componentes que concentram a maior parcela da variância não garante a preservação de toda a informação relevante para outros objetivos estatísticos. Isso é particularmente importante neste projeto, pois a PCA privilegia as direções de maior variabilidade, enquanto a Distância de Mahalanobis pode atribuir importância a desvios em direções de menor variabilidade.

9.2 Vantagens e limitações da Distância de Mahalanobis

A Distância de Mahalanobis apresentou uma vantagem particularmente relevante para o objetivo deste projeto, ela permitiu comparar os países considerando simultaneamente os quatro indicadores e suas relações de dependência. Dessa forma, o afastamento de um país não é determinado apenas pela magnitude de uma variável isolada, mas pelo seu perfil multivariado em relação ao centro da amostra.

Essa característica foi observada diretamente nos resultados. O Afeganistão apresentou a maior distância quadrática, $D_M^2 = 18,758$, mas sua principal contribuição não veio da PC1, que representa a maior parte da variabilidade global. A maior contribuição veio da PC4, com 10,673. O Turcomenistão, por outro lado, apresentou $D_M^2 = 18,022$, com contribuição predominante da PC2 (11,927), enquanto a Coreia do Norte apresentou $D_M^2 = 17,672$, com 16,018 provenientes da PC3. Portanto, países com distâncias elevadas podem apresentar perfis afastados por mecanismos diferentes dentro da estru-

tura multivariada.

Essa decomposição constitui uma vantagem adicional da utilização conjunta com a PCA, pois permite ir além da simples ordenação dos países pelas distâncias. Em vez de apenas identificar quais observações estão mais afastadas, é possível investigar quais direções da estrutura multivariada são responsáveis por esse afastamento.

Entretanto, a aplicação também apresentou limitações importantes. A Distância de Mahalanobis depende da matriz de covariâncias estimada a partir da própria amostra. Portanto, observações muito afastadas podem modificar tanto a estimativa do centro quanto a estrutura de dispersão utilizada no cálculo da distância. Esse problema é particularmente relevante neste estudo, pois justamente alguns dos países que apresentam as maiores distâncias podem exercer influência sobre as quantidades utilizadas para calculá-las.

A análise dos resultados deve, portanto, distinguir entre um país que apresenta um perfil energético realmente afastado do restante da amostra e uma observação que, além de afastada, exerce influência suficiente para alterar a estrutura estimada. O simples fato de apresentar uma distância elevada não constitui justificativa para excluir uma observação. No contexto deste projeto, países com perfis extremos são justamente parte do fenômeno que se pretende caracterizar.

Outra limitação está relacionada à normalidade multivariada. Os testes realizados indicaram evidências contra a hipótese de normalidade multivariada. Essa limitação também restringe a interpretação inferencial dos valores obtidos, razão pela qual as distâncias foram utilizadas neste projeto como medidas descritivas de afastamento.

Além disso, a interpretação da Distância de Mahalanobis depende da matriz de covariâncias. A dependência da estimativa e inversão dessa matriz constitui uma limitação que se torna mais relevante em situações com maior número de variáveis ou com dependências lineares mais fortes. Embora essa questão não tenha impedido o cálculo realizado, ela deve ser considerada em aplicações de maior dimensionalidade.

9.3 Complementaridade entre PCA e Distância de Mahalanobis

Os resultados obtidos mostram que PCA e Distância de Mahalanobis respondem a perguntas diferentes sobre o mesmo conjunto de dados. A PCA identifica as direções que concentram a maior parte da variabilidade observada, enquanto a Distância de Mahalanobis mede o afastamento de cada observação levando em conta toda a estrutura de variâncias e covariâncias.

Essa diferença fica particularmente clara no comportamento da PC4. Embora ela explique apenas 1,10% da variância total, seu pequeno autovalor faz com que desvios nessa direção tenham peso elevado na Distância de Mahalanobis.

Assim, os resultados do projeto mostram que reduzir os dados às primeiras componentes pode ser apropriado para visualização e interpretação da variabilidade

global, mas não necessariamente para preservar uma medida de afastamento multivariado. A utilização conjunta das duas técnicas permitiu identificar justamente essa diferença, que poderia não ser observada caso apenas uma das abordagens fosse utilizada.

9.4 Possíveis melhorias e extensões

Os resultados obtidos permitem identificar algumas extensões diretamente relacionadas às limitações observadas no projeto. A primeira seria realizar uma análise de sensibilidade em relação às decisões tomadas durante a análise. Como a transformação logarítmica reduziu a assimetria, mas não levou à normalidade multivariada, uma extensão seria comparar essa escolha com outras transformações e verificar se os autovalores, coeficientes das componentes e principais países identificados permanecem semelhantes.

Também seria importante avaliar a influência das observações que apresentaram maiores Distâncias de Mahalanobis. Uma possibilidade seria calcular novamente a PCA e as distâncias após a retirada temporária de algumas das observações mais afastadas e comparar os resultados com aqueles obtidos na amostra completa. Caso a estrutura das componentes e a ordenação dos países permaneçam semelhantes, haveria evidências de maior estabilidade da análise. Por outro lado, mudanças expressivas indicariam que os resultados dependem fortemente de determinados perfis energéticos.

Uma segunda extensão seria comparar a abordagem clássica utilizada no projeto com versões robustas da PCA e da Distância de Mahalanobis. Essa comparação seria particularmente adequada porque a análise identificou países com valores elevados de distância e mostrou que algumas componentes de pequena variância possuem grande influência no afastamento de determinadas observações. Métodos robustos poderiam ser utilizados para avaliar se esses padrões permanecem quando a estimativa da localização e da dispersão é menos sensível às observações extremas.

Outra possibilidade seria investigar a estabilidade da PCA por meio de reamostragem. Os autovalores e os coeficientes das componentes poderiam ser recalculados em diferentes amostras, permitindo verificar se a concentração de 88,90% da variância nas duas primeiras componentes e a interpretação dos coeficientes permanecem estáveis diante de alterações na composição da amostra.

Por fim, a análise poderia ser complementada por técnicas de agrupamento. A Distância de Mahalanobis mostrou que os países mais afastados não necessariamente se afastam pelo mesmo motivo: o Turcomenistão apresentou predominância da PC2, a Coreia do Norte da PC3 e Afeganistão e Luxemburgo da PC4. Uma análise de agrupamento poderia investigar se esses diferentes padrões de afastamento estão associados a grupos de países com perfis energéticos semelhantes, complementando a perspectiva contínua fornecida pela PCA e pela Distância de Mahalanobis.

De maneira geral, os resultados indicam que a combinação das duas técnicas foi adequada para os objetivos exploratórios propostos. A PCA permitiu resumir grande

parte da variabilidade dos quatro indicadores em duas componentes e identificar as principais estruturas de associação entre as variáveis, enquanto a Distância de Mahalanobis permitiu quantificar e decompor os afastamentos dos países considerando a estrutura multivariada. Ao mesmo tempo, a análise mostrou que a ausência de normalidade multivariada, a sensibilidade das estimativas às observações extremas e a diferença entre a variabilidade global e a importância de determinadas componentes para as distâncias devem ser consideradas na interpretação. Dessa forma, os resultados obtidos são úteis para caracterizar a estrutura multivariada dos indicadores analisados, mas devem ser entendidos como uma análise exploratória da amostra, cuja estabilidade poderia ser investigada em maior profundidade por meio das extensões propostas.

Referências

- [1] Our World in Data. Energy data. <https://ourworldindata.org/energy>, 2026. Acesso em: 2 out. 2026.
- [2] Posit. Rstudio: Integrated development environment for r. <https://posit.co/products/open-source/rstudio/>, 2026. Acesso em: 2 out. 2026.
- [3] Richard A. Johnson and Dean W. Wichern. *Applied Multivariate Statistical Analysis*. Prentice Hall, Upper Saddle River, 4 edition, 1998.